

Proyecto 1 — Fase A: Diseño de la Bodega de Datos

Estadísticas delictivas de Colombia 2025 (DIJIN) · Grupo 7 · Héctor Fabio Ocampo Arbeláez — R.A. 1

1. Fuente y alcance de los datos

La fuente son 8 reportes **.xlsx** publicados por la Policía Nacional — Dirección de Investigación Criminal e INTERPOL (DIJIN), Grupo de Información de Criminalidad: Homicidio Intencional, Homicidios en Accidente de Tránsito, Hurto a Personas, Hurto a Residencias, Hurto Piratería Terrestre, Secuestro, Terrorismo y Violencia Intrafamiliar, todos con corte 2025. Tras eliminar las filas de pie de página de cada archivo (créditos y fuente, sin código DANE), la bodega consolida **480.091** casos delictivos.

2. Modelo elegido: estrella

Se eligió un **modelo estrella** (no copo de nieve) porque las 5 dimensiones identificadas no requieren normalización adicional: cada una es una lista relativamente pequeña y estable de valores (hasta 1.500 combinaciones en el caso de geografía) que no gana claridad al descomponerse en subtablas. Un modelo estrella también simplifica las consultas de la Fase C, ya que cada dimensión se une a la tabla de hechos en un solo salto.

3. Grano de la tabla de hechos

hecho_delito — una fila = un caso delictivo registrado por la Policía Nacional en 2025. Es el grano más fino que entrega la fuente (cada archivo ya viene desagregado a nivel de caso individual, con *CANTIDAD* = 1 en la inmensa mayoría de filas), por lo que no se agregó nada durante la extracción: agregar antes de cargar habría impedido responder preguntas a nivel de caso individual más adelante.

4. Diagrama de la bodega



5. Dimensiones y justificación

dim_tiempo

Atributos: fecha_id (PK), fecha, anio, trimestre, mes, nombre_mes, dia, dia_semana, es_fin_de_semana

Cardinalidad: 365 filas (una por día de 2025)

Permite analizar la evolución temporal de los delitos a distintos niveles de detalle (mes, trimestre, día de la semana) sin recalcular fechas en cada consulta. Se agregó *es_fin_de_semana* porque el patrón fin de semana vs. entre semana es una pregunta de negocio explícita del grupo (Consulta 6, Fase C).

dim_geografia

Atributos: geo_id (PK), codigo_dane, departamento, municipio

Cardinalidad: 1.500 filas (combinaciones únicas de departamento-municipio)

Captura la jerarquía departamento → municipio en una sola tabla (en vez de dos tablas separadas, lo que sería un copo de nieve) porque el número de combinaciones es pequeño y estable. Permite comparar la incidencia delictiva por región a distintos niveles de agregación.

dim_tipo_delito

Atributos: delito_id (PK), tipo_delito

Cardinalidad: 8 filas (una por archivo fuente)

El tipo de delito no viene como columna en los archivos originales — se deriva del nombre del archivo durante la extracción. Es la dimensión central para comparar la frecuencia relativa de los 8 delitos entre sí.

dim_arma_medio

Atributos: arma_id (PK), arma_medio

Cardinalidad: 23 filas

Agrupar el arma o medio empleado (arma de fuego, arma blanca, sin empleo de armas, etc.). Es clave para entender qué tan violento es cada tipo de delito y para priorizar estrategias de intervención según el medio usado.

dim_victima

Atributos: victima_id (PK), genero, grupo_edad

Cardinalidad: 10 filas (combinaciones de género × grupo de edad, incluyendo "NO REPORTADO")

Dos de los ocho archivos (Terrorismo y Hurto Piratería Terrestre) no traen género ni edad de la víctima, y los demás archivos tienen valores nulos puntuales. En vez de descartar esas filas o dejarlas con NULL, se creó una categoría explícita "NO REPORTADO" para no perder los casos y para que quede documentado que el dato no está disponible, no que se perdió en el proceso.

6. Tabla de hechos

hecho_delito — hecho_id (PK), fecha_id (FK), geo_id (FK), delito_id (FK), arma_id (FK), victima_id (FK), cantidad (medida). 480.091 filas, una por cada caso delictivo consolidado. La medida *cantidad* es aditiva en las 5 dimensiones (admite SUM sin restricciones), lo que simplifica las consultas de agregación de la Fase C.

7. Validaciones aplicadas

- El número de filas de hecho_delito coincide exactamente con el número de filas limpias del consolidado (480.091), confirmando que ningún join de la Fase B perdió ni duplicó registros.
- Ninguna llave foránea de hecho_delito quedó nula tras los merges con las 5 dimensiones.

- Cada código DANE se asoció a un único municipio (no hay códigos duplicados con municipios distintos), validando la jerarquía geográfica.