Predicción y segmentación de casos delictivos en Colombia 2025

Limpieza, modelado supervisado y no supervisado sobre las estadísticas de la DIJIN — Informe final del Proyecto 2 y 3

INTEGRANTES
Juan David Quintero Garcia (2559710)
Juan Jose Ospina (2559711)
Miguel Angel Arboleda (2160253)
Juan David Ascensio (2359660)

DOCENTE
Héctor Fabio Ocampo Arbeláez

CURSO Y FECHA
Introducción a la ciencia de los datos
R.A. 2 y 3 · Grupo 7 · Octubre de 2026

REPOSITORIO
github.com/001Miguel15cn/Grupo-7-p-1
Carpeta *grupo-7-p2p3*

Resumen ejecutivo

Se tomaron los **480.091 casos** de ocho delitos registrados por la Policía Nacional (DIJIN) en 2025 y se respondió una pregunta práctica: **¿cuántos casos registrará cada municipio el mes siguiente?** Un modelo de *Gradient Boosting* reduce el error ~8 % frente a la regla "repetir el mes anterior" en escala logarítmica (R^2 0,870 frente a 0,797) y 30 % en municipios de 1 a 4 casos; es el único de los tres modelos que también supera esa regla en las capitales (R^2 0,986 vs. 0,983). Además, un K-Means separa los municipios en 5 perfiles delictivos interpretables. La mejora es modesta: el mes anterior ya es un predictor muy fuerte, y las cifras de noviembre-diciembre están afectadas por rezago de reporte.

1. Contexto del dataset y pregunta de negocio

Los ocho reportes (hurto a personas, hurto a residencias, piratería terrestre, violencia intrafamiliar, homicidio intencional, homicidio en accidente de tránsito, secuestro y terrorismo) traen **un caso por fila** y casi todas sus columnas son categóricas (arma, departamento, municipio, género, edad). La única numérica, *CANTIDAD*, vale 1 en todas las filas, por lo que no admite histogramas, correlaciones ni escalado. Para poder aplicar las técnicas del curso los casos se agregaron a un **panel unidad territorial × mes** (**1.500 unidades territoriales DANE × 12 meses = 18.000 filas**) con variables numéricas reales: casos por familia de delito, días con casos, y porcentajes de fin de semana, víctimas mujeres, arma de fuego y edad.

Unidad territorial. El *CODIGO DANE* de la DIJIN tiene 8 dígitos: 5 del municipio y 3 del centro poblado. Los 1.500 códigos corresponden a 1.105 cabeceras municipales (sufijo 000) y 395 centros poblados (corregimientos e inspecciones) que pertenecen a 1.106 municipios; esos 395 centros poblados reúnen solo 1.264 casos (0,26 %). Valledupar, por ejemplo, aparece con 15 códigos. El panel usa el código completo como llave y, **por brevedad, en adelante el texto llama "municipio" a cada unidad territorial**.

La pregunta ("proyección de casos por mes", el siguiente paso planteado en el Proyecto 1) es un problema de **regresión**: la variable objetivo es el número de casos del municipio en el mes. Para que sea una predicción y no una identidad, las variables explicativas usan solo información del mes anterior o acumulada hasta él.

2. Análisis exploratorio (Fase A)

Se generaron histogramas, boxplots, mapas de calor de Pearson y Spearman y tres gráficos adicionales (todos con su insight en el notebook *fase_a_eda.ipynb*). Las distribuciones son muy asimétricas (asimetrías de 16 a 60), lo que anticipa la transformación logarítmica y el escalado robusto. Tres hallazgos sobresalen:

Hallazgo 1 — El delito está extremadamente concentrado. Bogotá reúne el 37,5 % de los casos. 39 de las 1.500 unidades (2,6 %) suman el 80 %; a nivel de municipio, 38 de 1.106 (3,4 %). En el otro

extremo, 757 unidades (50,5 %) registran menos de 20 casos al año; a nivel de municipio son 369 (33 %), porque muchos centros poblados casi no registran casos.

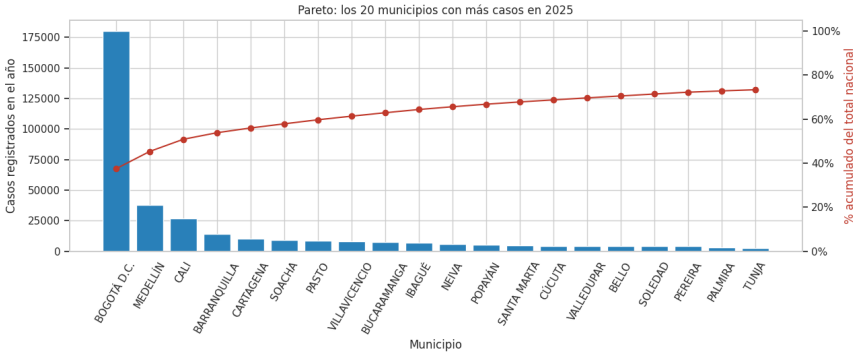


Figura 1. Pareto de los 20 municipios con más casos: los 5 primeros acumulan el 56 % del total nacional.

Hallazgo 2 — La caída de fin de año parece rezago de reporte. Los casos pasan de 46.611 en octubre a 30.872 en diciembre (−34 %), pero los homicidios, que se registran de inmediato, no caen (1.730 en octubre, 1.837 en noviembre y 1.884 en diciembre); la violencia intrafamiliar cae 49 % y el hurto 30 %.

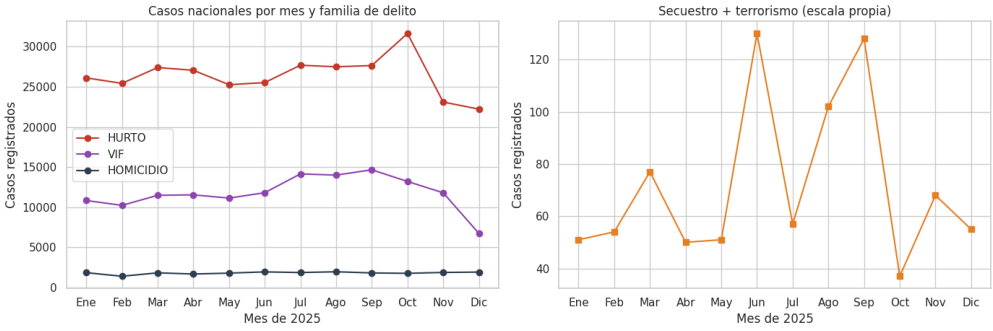


Figura 2. Casos por mes y familia de delito: los homicidios no acompañan la caída de noviembre-diciembre.

Hallazgo 3 — El mes anterior predice muy bien el siguiente. La correlación entre los casos de un mes y los del mes anterior es 0,90 en escala log ($R^2 \approx 0{,}80$), y cuando el mes anterior fue 0, el siguiente también fue 0 en el 71 % de los casos. Este hallazgo define el problema supervisado y fija la regla ingenua que los modelos deben superar.

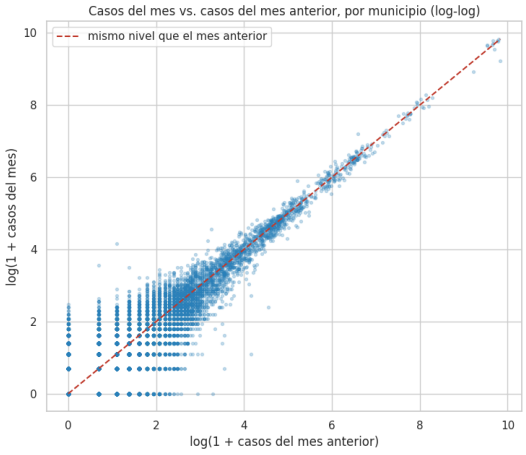


Figura 3. Casos del mes frente a casos del mes anterior por municipio (log-log). La línea punteada marca "el mismo nivel que el mes anterior".

Pearson frente a Spearman. Comparar ambos coeficientes muestra cuánto de la correlación depende de unas pocas ciudades. Entre casos y días activos Pearson da 0,22 y Spearman 0,99: Bogotá, con miles de casos y 31 días activos, arrastra la medición lineal, mientras que los rangos revelan que donde hay más casos hay delito más días. Los porcentajes de perfil (género, arma, fin de semana) son casi independientes del volumen ($|r| \approx 0$), pero se relacionan entre sí: más arma de fuego va con menos casos "sin armas" (−0,58) y con menos víctimas mujeres (−0,37).

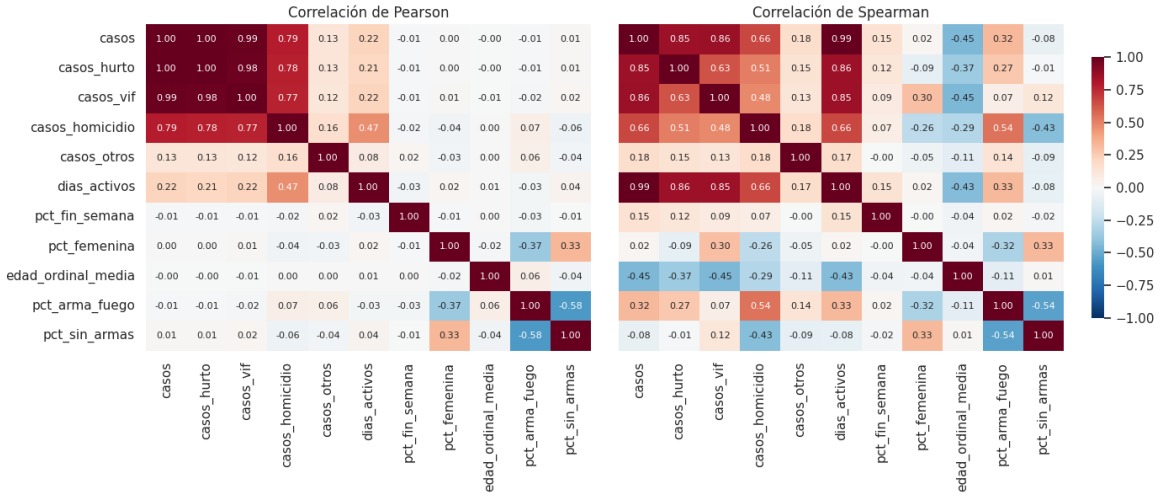


Figura 4. Correlación de Pearson (izquierda) y de Spearman (derecha) entre las variables del panel municipio-mes; ambas matrices tienen el mismo orden de filas y columnas.

3. Limpieza y normalización (Fase B)

El pipeline parte de los ocho Excel crudos y deja constancia de cada decisión. Las más importantes:

Paso	Decisión	Justificación
Pie de página	Eliminar 40 filas	No tienen código DANE: son créditos, no casos.
Duplicados	**Conservar** 301.560 filas idénticas (63 %)	La fuente no trae ID de caso y CANTIDAD = 1; son casos distintos. El panel suma exactamente 480.091, igual que el Proyecto 1.
Texto	Mayúsculas, sin “(CT)”, llave = código DANE	291 nombres aparecen con varios códigos, sobre todo porque un municipio tiene varios centros poblados (p. ej., Valledupar, 15 códigos) y también por homónimos entre departamentos. Cada código tiene un solo nombre.
Armas raras	Agrupar en “OTRO” las 13 categorías con < 0,1 % de los casos	Casi vacías: no aportan señal e inflarían las columnas. “NO REPORTADO” se conserva como categoría.
Nulos categóricos (género, edad)	**Moda** por tipo de delito (puntuales: 1.168 de género y 577 de edad); no imputar los estructurales	La moda global asignaría “masculino” a violencia intrafamiliar. Terrorismo y piratería nunca registran víctima.
Nulos numéricos (porcentajes sin historial)	**KNN (k=5)** + bandera de “sin historial”	En un experimento con valores ocultos, KNN gana a la media y a la mediana en 4 de 5 variables (error relativo 0,86 vs. 0,93 y 1,00).
Atípicos	**Conservar**; mitigar con log1p y RobustScaler	12,6 % son atípicos por IQR (solo 0,24 % por Z-score), pero son Bogotá, Medellín, Cali: reales y justo lo que se quiere predecir.
Asimetría	log1p en 7 conteos	Hay ceros reales; Box-Cox no los admite. La asimetría de los casos del mes anterior baja de 44 a 1,5.
Codificación	One-Hot (drop_first) para departamento y perfil dominante; **ordinal** para la edad (menores < adolescentes < adultos)	Los primeros no tienen orden (drop_first evita colinealidad en la regresión lineal); la edad sí.
Escalado	**RobustScaler** (comparado con Min-Max y Z-score)	Resiste a los municipios grandes que se conservaron: Min-Max deja a la mitad por debajo de 0,07 y Z-score produce máximos de 6,5.
Fuga de datos	Partición 80/20 **antes** de ajustar nada	Medianas, vecinos KNN, escalas y cortes se aprenden solo con entrenamiento (sección 3.1).

El resultado es *datos_limpios.parquet*: 16.500 filas (febrero a diciembre; enero no tiene mes anterior) × 59 columnas, sin nulos, con 13.200 filas de entrenamiento y 3.300 de prueba.

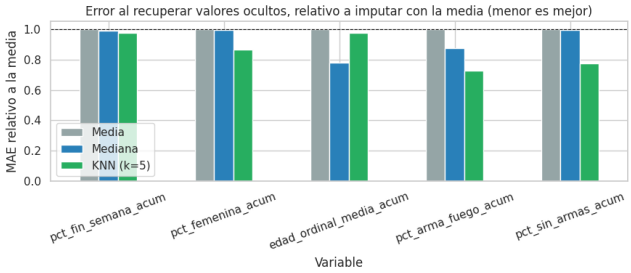


Figura 5. Experimento de imputación: error al recuperar valores ocultos, relativo a imputar con la media (menos de 1 es mejor).

3.1 Cómo se evitó la fuga de información (data leakage)

- **Primero la partición.** El panel se dividió 80/20 con *train_test_split(random_state=42)* (13.200 / 3.300 filas) **antes** de aprender cualquier estadístico: la mediana y el IQR del RobustScaler, los vecinos del KNNImputer, el corte IQR de atípicos y la asimetría que decide qué variables llevan log1p se calculan solo con entrenamiento. La Fase C verifica con una aserción que la partición es la misma.
- **Solo información del pasado.** Cada fila usa variables del mes anterior o acumuladas hasta él, nunca del mes que se predice; una aserción de la Fase B comprueba que el acumulado no incluye el mes actual.
- **Exclusiones explícitas.** *casos*, *y_log1p* y *atipico_iqr* (calculada con el valor del mes objetivo) no son variables explicativas; otra aserción lo garantiza.
- **Prueba intacta.** Los hiperparámetros se ajustaron con validación cruzada de 3 pliegues solo sobre entrenamiento, y todas las métricas se reportan sobre el conjunto de prueba.

Nota honesta. La imputación por moda por tipo de delito (1.745 valores en 480.091 casos) y la agrupación de armas raras se calcularon con todos los casos, antes de la partición. Su efecto es despreciable: son limpieza a nivel de caso que precede a la construcción del panel, no estadísticos del objetivo.

4. Modelos y comparación de desempeño (Fase C)

Se entrenaron **tres modelos supervisados del mismo tipo (regresión)**, con la misma partición, las mismas 50 variables y el mismo objetivo: Regresión Lineal, Random Forest y Gradient Boosting; más un modelo no supervisado (K-Means, sección 5). Los hiperparámetros se ajustaron con búsqueda aleatoria y validación cruzada de 3 pliegues **solo sobre el entrenamiento**; todas las métricas son del conjunto de prueba. Como referencia (no como modelo) se incluye la **regla ingenua** "este mes = el mes anterior".

Decisión de diseño. Los modelos predicen la *variación* respecto al mes anterior y la predicción final suma ese nivel base. Con el nivel directo el Random Forest alcanzaba un R^2 de apenas 0,68 en escala de casos porque los árboles no extrapolan hasta los miles de casos de Bogotá; con la variación sube a 0,97.

Modelo	R^2 (log)	RMSE (log)	MAE (log)	MSE (log)
Regla ingenua (referencia)	0,797	0,613	0,409	0,375
Regresión Lineal	0,869	0,493	0,377	0,243
Random Forest	0,869	0,492	0,377	0,242
Gradient Boosting	**0,870**	**0,489**	**0,375**	**0,240**

Modelo	R^2 (casos)	RMSE (casos)	MAE (casos)	MSE (casos)
Regla ingenua (referencia)	0,983	85,2	6,95	7.250
Regresión Lineal	0,949	148,4	8,76	22.037
Random Forest	0,971	112,5	7,87	12.667
Gradient Boosting	**0,986**	**78,5**	**6,45**	**6.162**

Tablas 1 y 2. Métricas en el conjunto de prueba (3.300 filas) en escala log y en casos por mes (donde pesan las capitales).

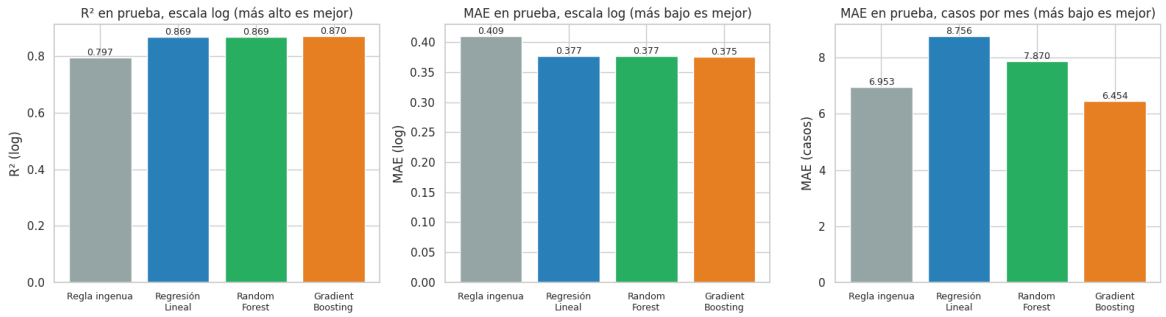


Figura 6. Comparación de métricas en prueba.

Lectura. Los tres modelos superan a la regla ingenua en escala log y la mejora es real (intervalo de confianza bootstrap de la diferencia de MAE: −0,046 a −0,023 para Gradient Boosting). Entre los tres modelos, en cambio, las diferencias **no son estadísticamente significativas** (el intervalo contra la Regresión Lineal es −0,006 a 0,002). En escala de casos solo Gradient Boosting supera la regla ingenua.

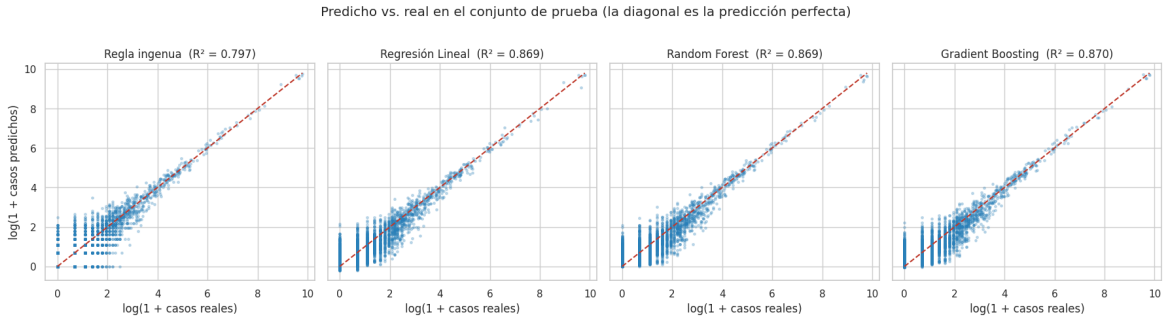


Figura 7. Predicho vs. real en prueba (escala log). La diagonal es la predicción perfecta.

¿Dónde acierta? La mejora está en la cola larga: el error baja 30 % en municipios con 1 a 4 casos, 11 % donde no hay casos y 10 % en los de 5 a 19; en los de 20 a 99 prácticamente empata (−1 %) y en los de 100 o más mejora 5 %. Las variables más importantes son el historial de actividad (casos acumulados 39 %, casos del mes anterior 30 %, días activos 10 %); el perfil de las víctimas o del arma pesa menos de 1,5 % cada uno.

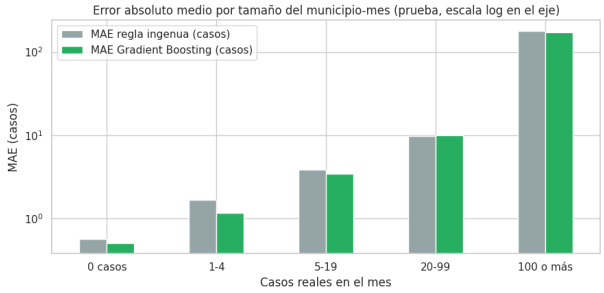


Figura 8. Error medio por tamaño del municipio-mes (eje logarítmico).

Robustez temporal. Entrenando con febrero-septiembre y probando con octubre-diciembre los tres modelos siguen superando la regla ingenua en escala log (error 0,376-0,391 vs. 0,405) y Gradient Boosting tiene el menor error en casos (5,7 vs. 6,2). La regla ingenua sobreestima +27 % en noviembre y +19 % en diciembre por el rezago de reporte, que ningún modelo entrenado con meses anteriores puede anticipar.

Modelo elegido: Gradient Boosting. Es el único que supera la regla ingenua en ambas escalas, tiene el menor error en casos en la validación temporal y no sobreajusta (R^2 0,868 en entrenamiento vs. 0,870 en prueba; el Random Forest pasa de 0,896 a 0,869). Con max_depth = 2 es un modelo poco complejo. Con honestidad: en escala log está estadísticamente empatado con la Regresión Lineal, así que si la prioridad fuera explicar cada predicción, la Regresión Lineal es una alternativa defendible. Las métricas de clasificación (matriz de confusión, ROC) no aplican a un problema de regresión; sus equivalentes aquí son el predicho vs. real y el error por tramo.

5. Segmentación de municipios (K-Means)

Con **606 de las 1.500 unidades (las de 30 o más casos; 98,4 % de los casos)** se estandarizó el perfil anual (volumen, participación de hurto, violencia intrafamiliar y homicidio, fin de semana, mujeres, arma de fuego, sin armas, edad) y se probó k de 2 a 8. El Silhouette es máximo en k = 2 (0,24), pero esa partición es una dicotomía burda; se eligió k = 5, el menor k ≥ 3 con Davies-Bouldin prácticamente mínimo (1,48), a costa de un Silhouette de 0,19.

Cluster	Unidades	Perfil dominante	Ejemplos
4 — Grandes ciudades	77 (86 % de los casos)	Hurto 62 %, volumen alto	Bogotá, Medellín, Cali, Barranquilla
1 — Violencia intrafamiliar	185	VIF 58 %, mujeres 59 %, arma de fuego 8 %	Apartadó, Caucasia, Tumaco
2 — Violencia armada	62	Homicidio 43 %, arma de fuego 41 %	Zona Bananera, Tibú, Andes
3 — Hurto	123	Hurto 58 %, más fin de semana (41 %)	Chiquinquirá, El Cerrito, Ubaté
0 — Intermedio mixto	159	Hurto 46 %, VIF 34 %, homicidio 20 %	Buenaventura, Quibdó, Riohacha

Tabla 3. Perfiles de los 5 clusters (promedios de cada grupo).

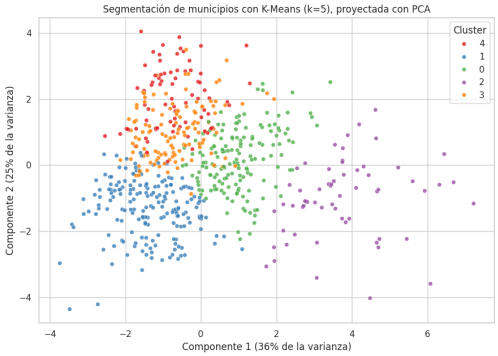


Figura 9. Municipios segmentados con K-Means (k = 5), proyectados con PCA.

La estructura es débil (Silhouette ≈ 0,19): los municipios forman más un continuo que grupos nítidos, así que los segmentos orientan la política pública (p. ej. enfoque de género en el grupo 1, control de armas en el 2) pero no son fronteras exactas.

6. Conclusiones y mejoras

Conclusiones. (1) El problema real del dataset no es de modelos sino de forma: sin agregar, no había variables numéricas que limpiar; el panel municipio-mes lo hizo posible. (2) La limpieza más decisiva fue *no* eliminar: se conservaron los duplicados (son casos) y los atípicos (son capitales). (3) El modelado mostró que el mes anterior ya es un estimador muy fuerte: los modelos mejoran, pero poco (~8 % en error log) y de forma significativa solo frente a la regla ingenua, no entre sí. (4) El valor práctico está en los municipios pequeños y medianos. (5) La segmentación aporta cinco perfiles accionables.

Limitaciones. Un solo año de datos (sin estacionalidad comprobable); casos registrados, no delito real; rezago de reporte en noviembre-diciembre; la partición aleatoria mezcla meses (por eso se añadió la validación temporal); sin población no se pueden calcular tasas por habitante. La unidad territorial mezcla cabeceras municipales y centros poblados, lo que multiplica las unidades con muy pocos casos. Al volver a ejecutar los notebooks en otro entorno cambia la tercera cifra decimal de algunas métricas (el desempate de vecinos del KNNImputer varía entre versiones de las librerías), sin cambiar ninguna conclusión.

Posibles mejoras. Más historia (2022-2024) para separar estacionalidad de rezago; población DANE para trabajar con tasas por 100 mil habitantes; variables de calendario (festivos, quincenas); un factor de corrección del rezago de reporte; modelos por segmento de tamaño guiados por el clustering; agregar los centros poblados a su municipio; otros algoritmos (HistGradientBoosting, modelos de conteo Poisson o binomial negativa) y una búsqueda de hiperparámetros más amplia.