PROYECTO 2 Y 3 · GRUPO 7

¿Cuántos casos tendrá cada municipio el mes que viene?

Predicción y segmentación de casos delictivos · Colombia 2025 (DIJIN)

Introducción a la ciencia de los datos · R.A. 2 y 3 · Octubre de 2026

INTEGRANTES

Juan David Quintero Garcia (2559710)

Juan Jose Ospina (2559711)

Miguel Angel Arboleda (2160253)

Juan David Ascensio (2359660)

Docente: Héctor Fabio Ocampo Arbeláez

El punto de partida

480.091
casos de 8 delitos · 2025

1.500
unidades territoriales DANE

18.000
filas: unidad × 12 meses

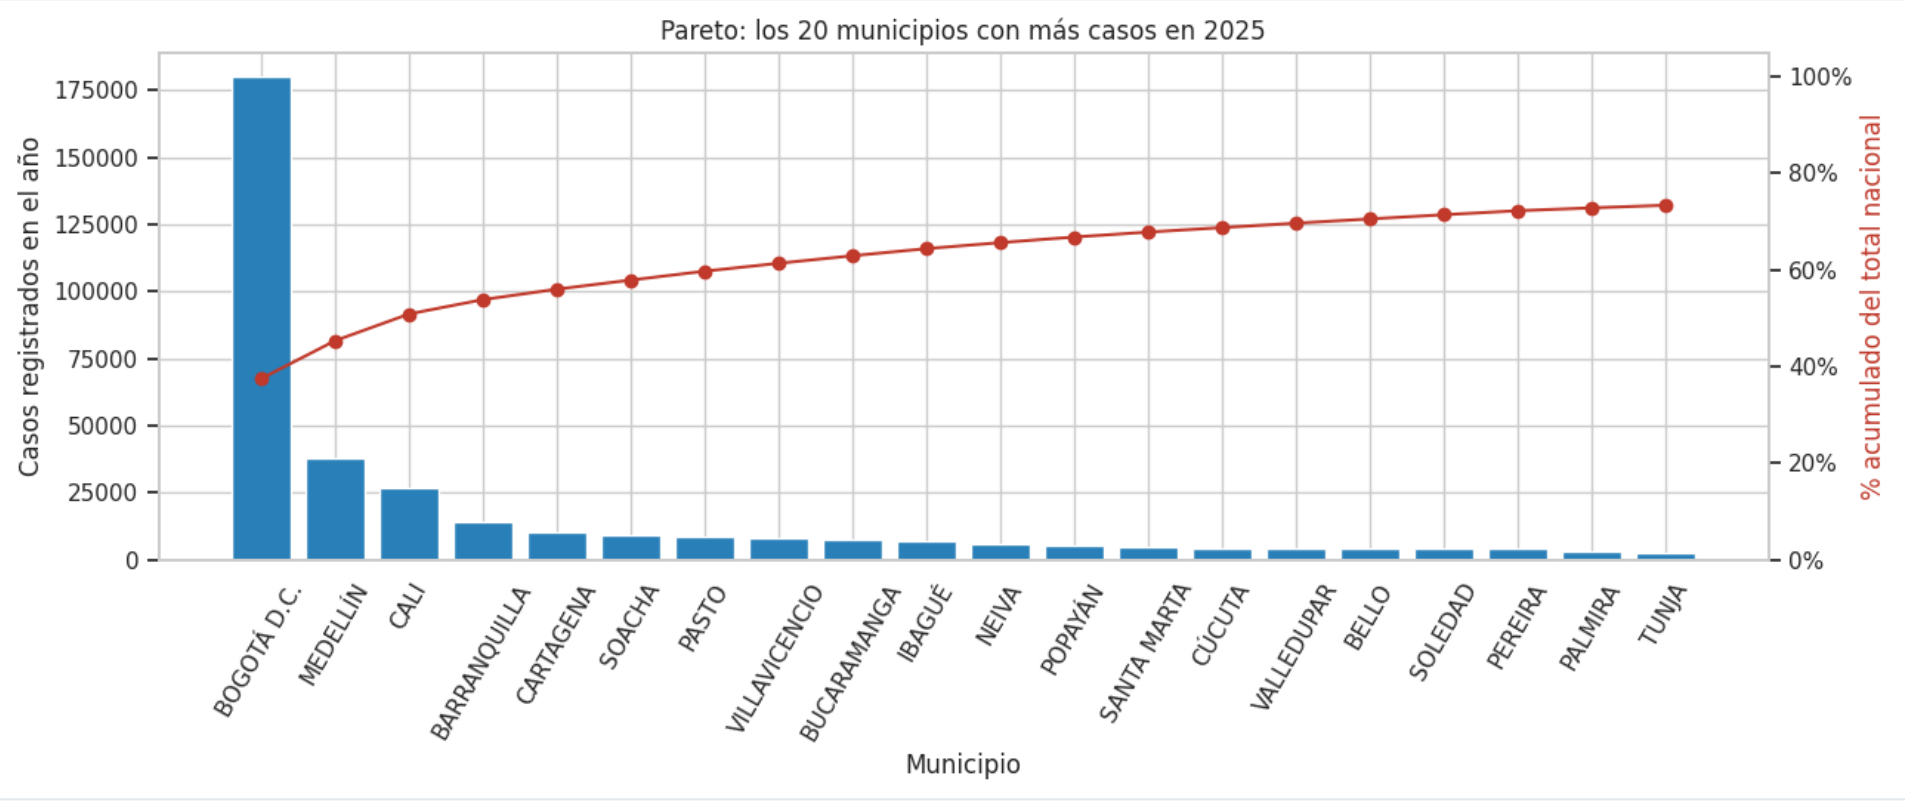
- Una fila = un caso: la única columna numérica (*CANTIDAD*) vale 1 → se agrega a un **panel unidad × mes**.
- Unidad = código DANE de 8 dígitos: **1.105 cabeceras + 395 centros poblados** (0,26 % de los casos), de 1.106 municipios. Por brevedad, “municipio”.
- Pregunta: **¿cuántos casos registrará cada municipio el mes siguiente?**



Ejemplo: **05001000** = Medellín, cabecera (sufijo 000).
Valledupar aparece con 15 códigos (cabecera y centros poblados).

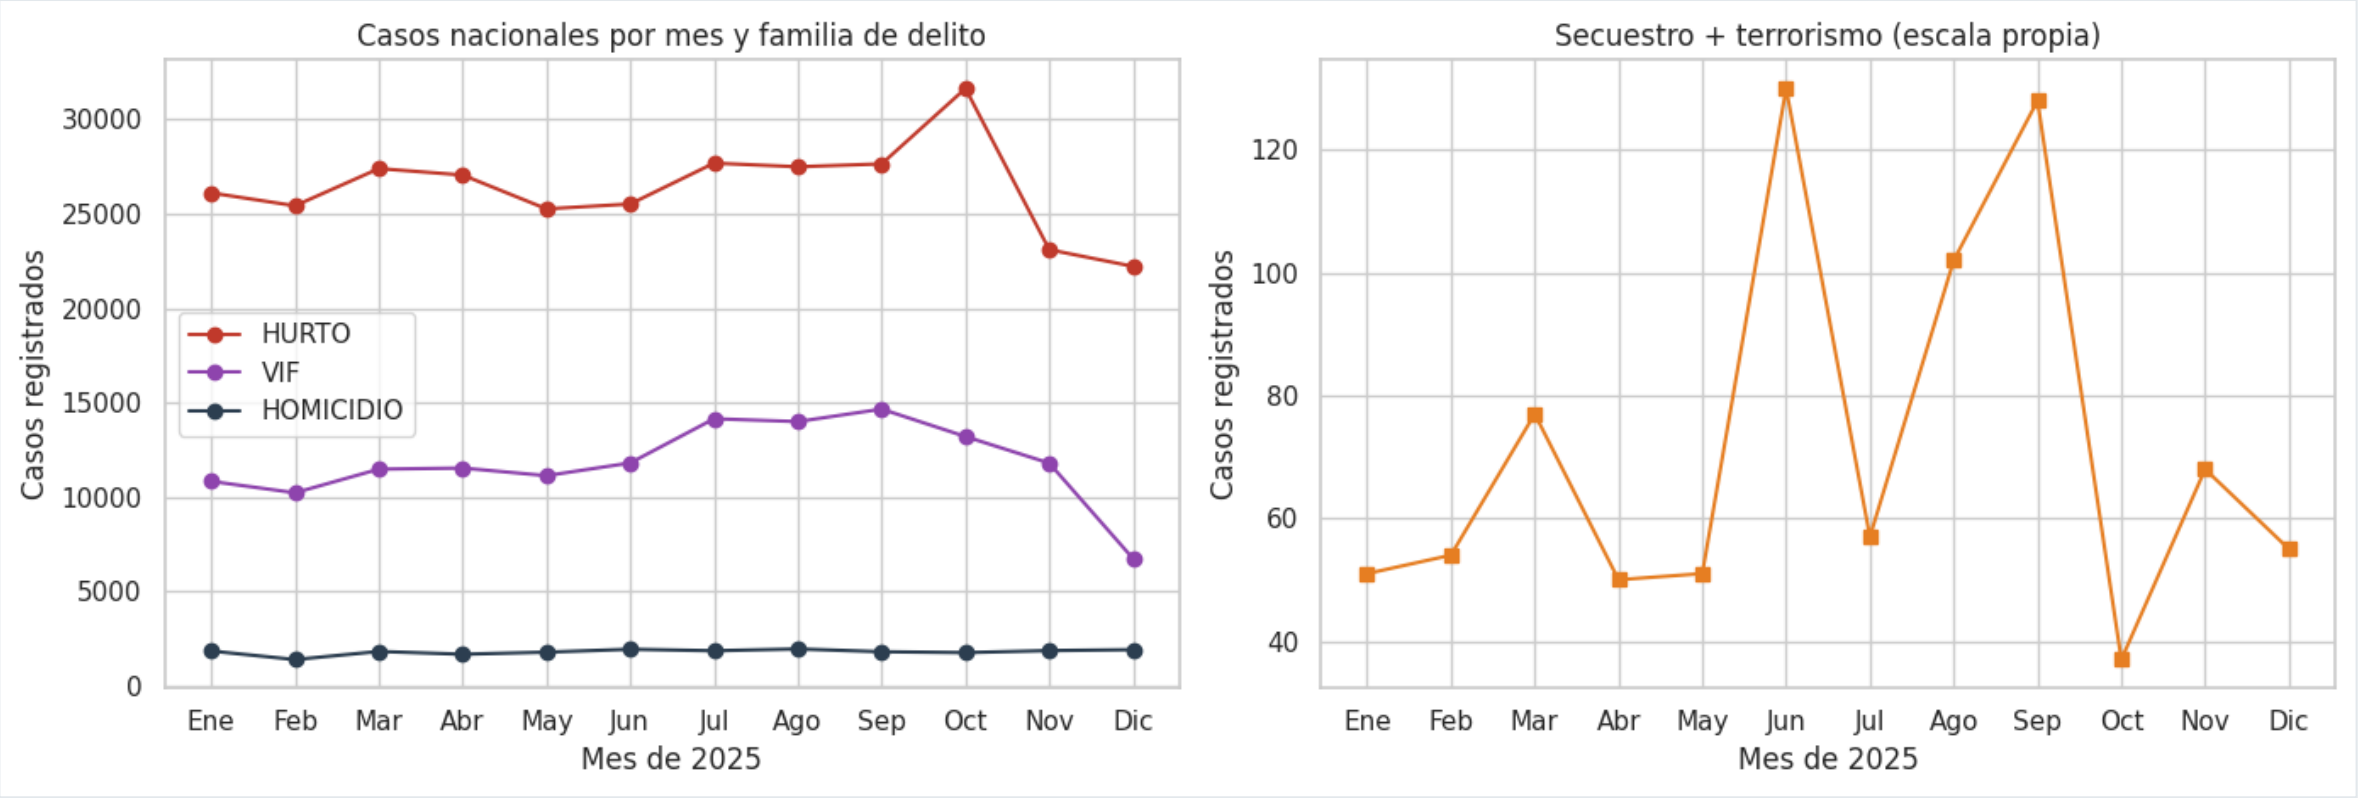
Hallazgo 1: el delito está concentrado

- Bogotá: **37,5 %** de los casos.
- **39 de 1.500 unidades (2,6 %)** suman el 80 % (38 de 1.106 municipios, 3,4 %).
- **757 unidades (50,5 %)** registran < 20 casos al año (369 municipios, 33 %).
- → Exige log, escalado robusto y métricas en dos escalas.



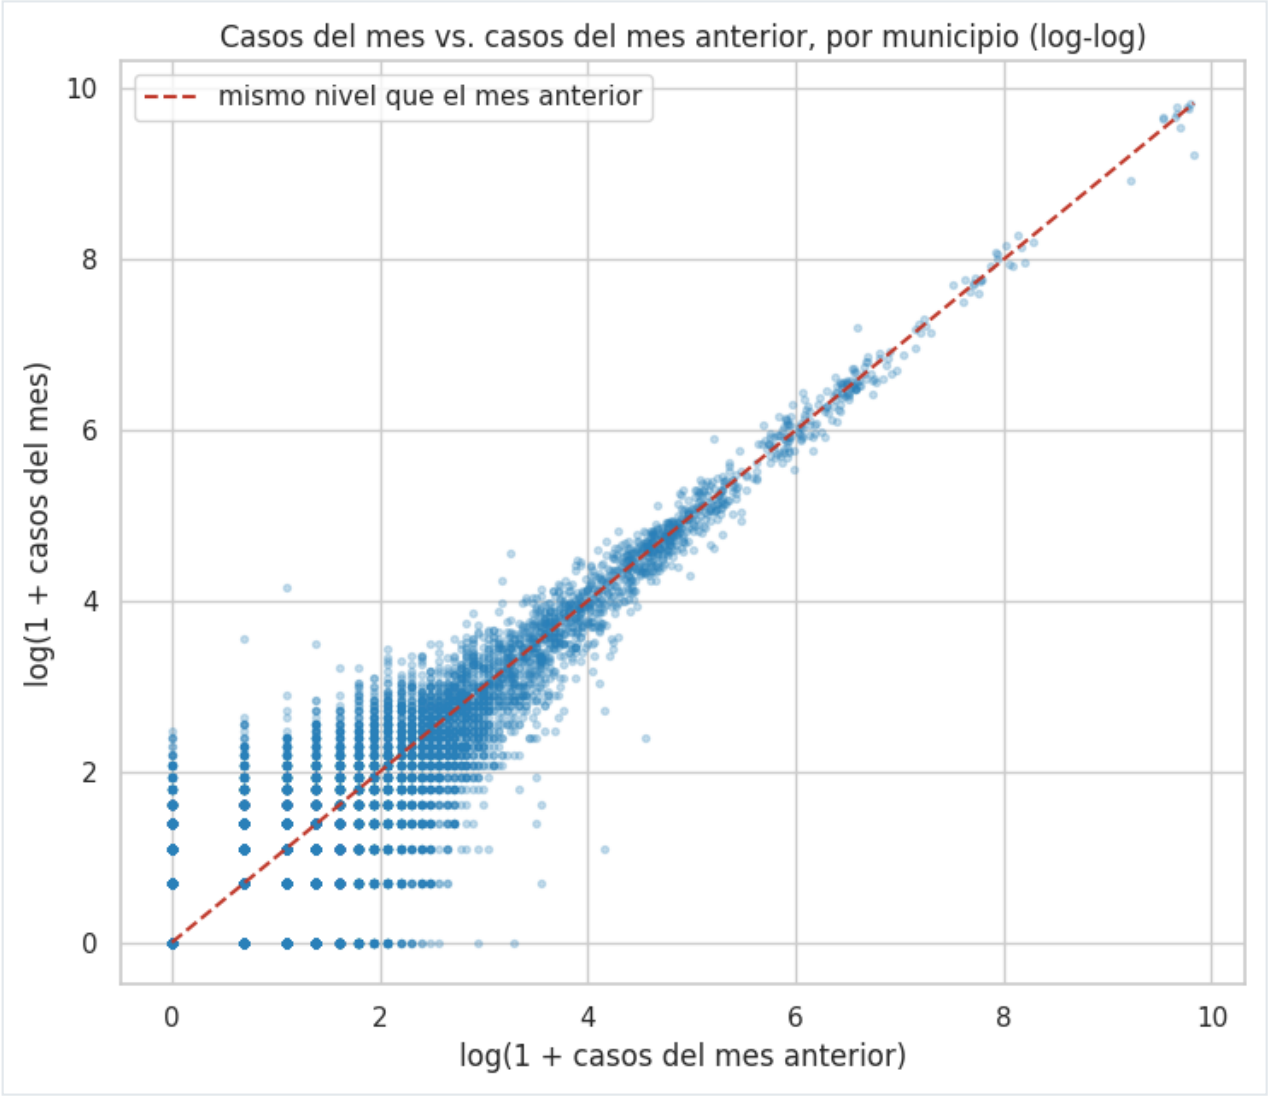
Hallazgo 2: la caída de fin de año es rezago

- Casos: 46.611 (oct) → 30.872 (dic): **−34 %**.
- Homicidios (se registran de inmediato) **no caen**: 1.730 (oct) → 1.884 (dic).
- VIF −49 %, hurto −30 % → **rezago de reporte**, no una baja real del delito.



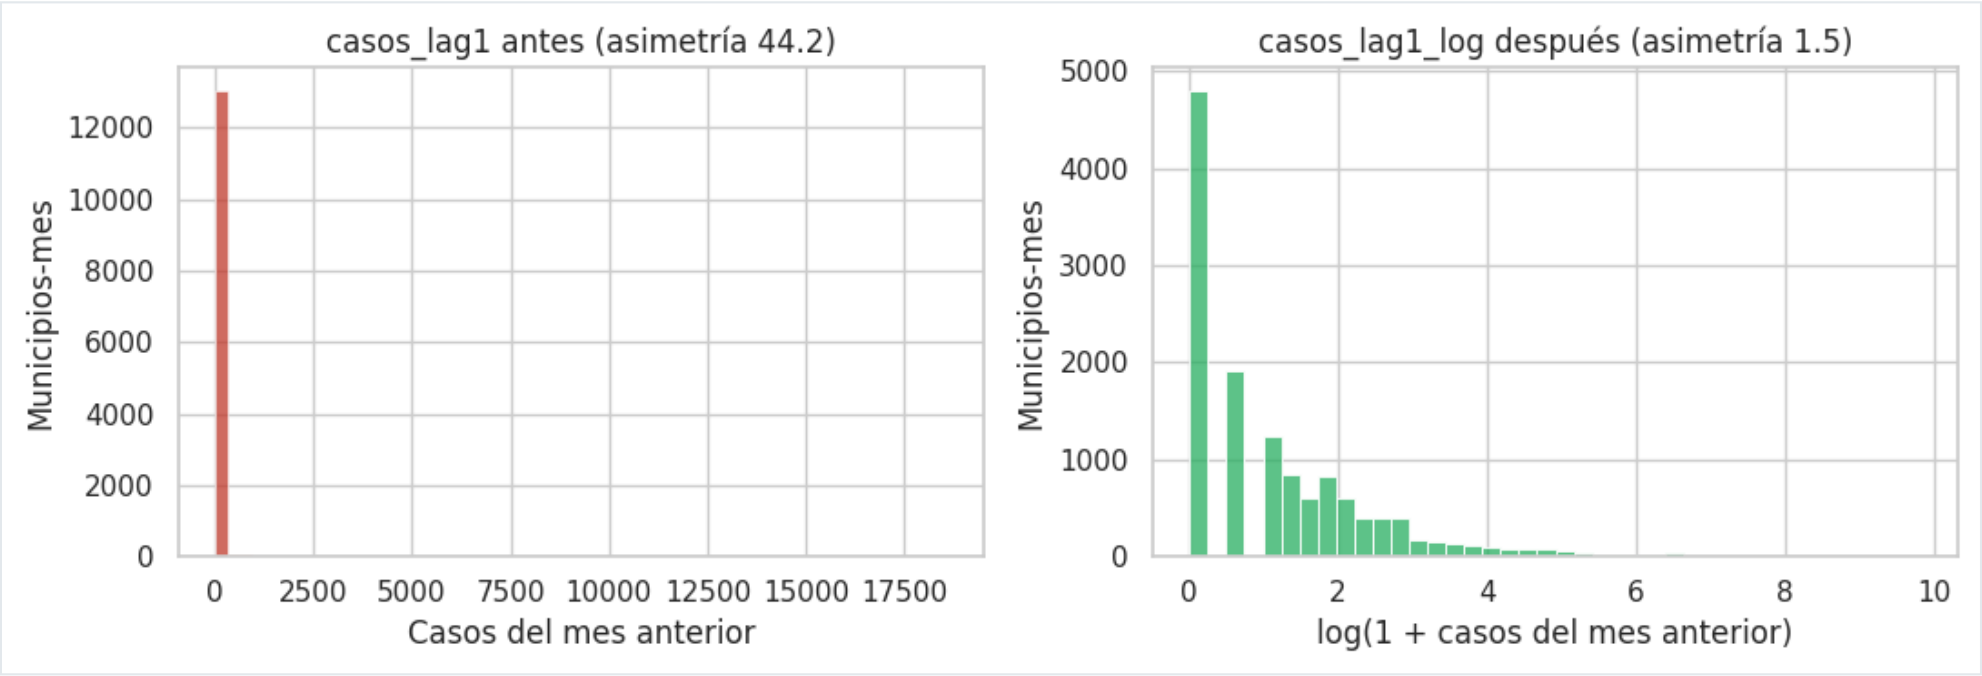
Hallazgo 3: el mes anterior predice el siguiente

- Correlación en escala log: **0,90** ($R^2 \approx 0,80$).
- Si el mes anterior fue 0, el siguiente también fue 0 en el **71 %** de los casos.
- → La **regla ingenua** “repetir el mes anterior” es la vara que todo modelo debe superar.

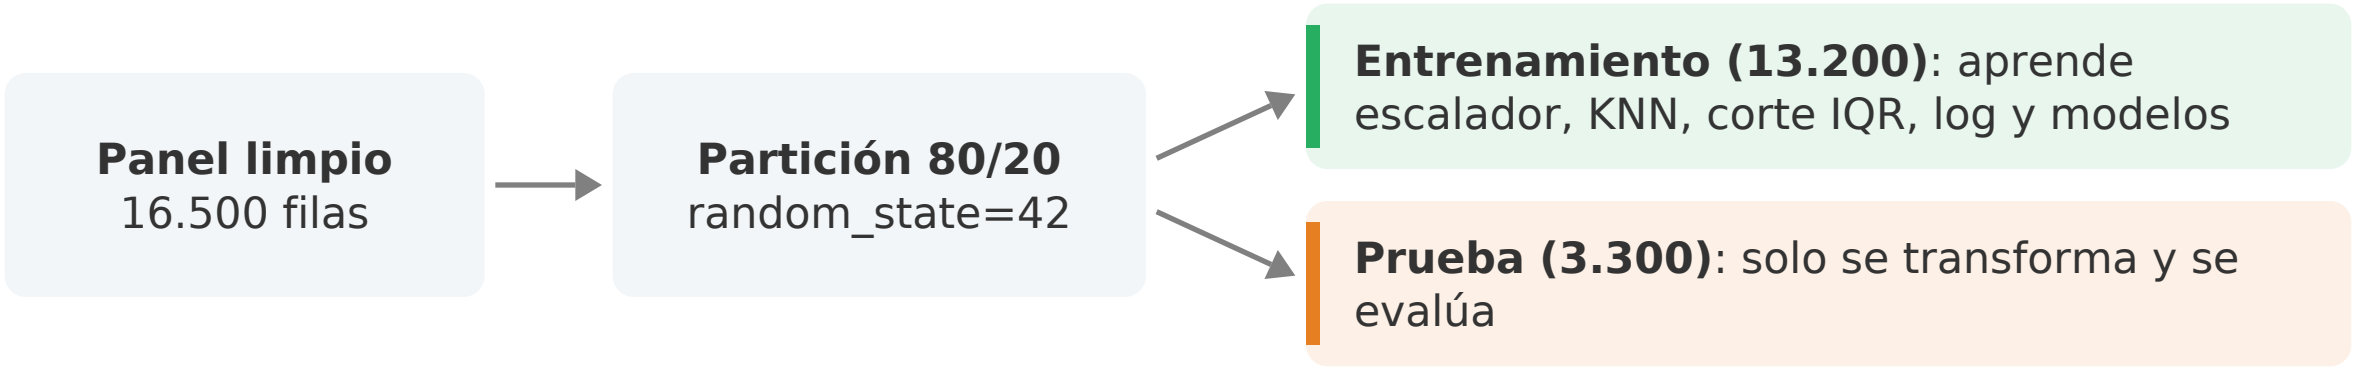


Limpieza: lo más importante fue NO eliminar

- **Duplicados (63 %): se conservan** — son casos distintos, sin ID de caso.
- **Atípicos (12,6 % por IQR): se conservan** — son Bogotá, Medellín, Cali.
- **log1p** + **RobustScaler**: la asimetría baja de 44 a 1,5 (gráfico).
- Nulos: **moda** por tipo de delito y **KNN** (ganó a media y mediana).
- One-Hot (drop_first) para departamento; **ordinal** para la edad.



¿Cómo evitamos hacer trampa? (data leakage)



- La partición va **antes** de aprender medianas, vecinos KNN, escalador o corte IQR.
- Variables solo del **mes anterior** o acumuladas hasta él.
- *casos*, *y_log1p* y *atipico_iqr* quedan **fuera** de las variables (aserción).
- Hiperparámetros con CV de 3 pliegues en entrenamiento; métricas **solo en prueba**.

Única excepción: la moda por tipo de delito (1.745 valores) y la agrupación de armas raras se calcularon antes del split; efecto despreciable (limpieza previa al panel).

Modelos: tres de regresión + K-Means

Mismo objetivo, mismas **50 variables** y misma partición:

Regresión Lineal

Simple e interpretable; sin hiperparámetros.

Random Forest

Búsqueda aleatoria + CV de 3 pliegues.

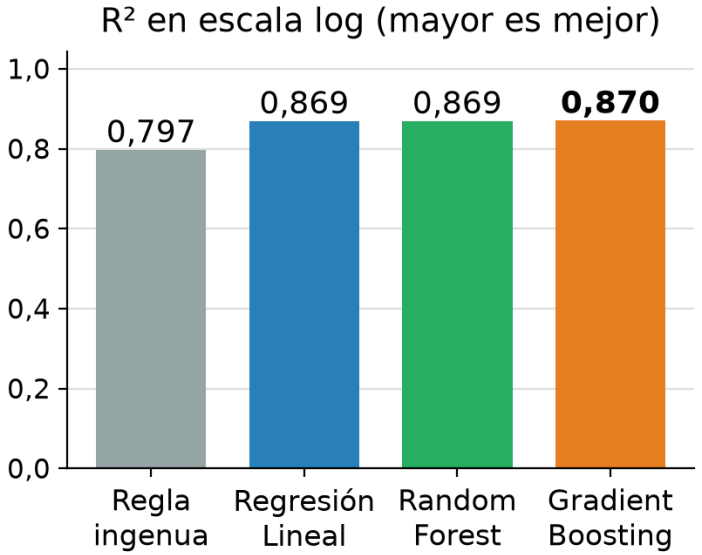
Gradient Boosting

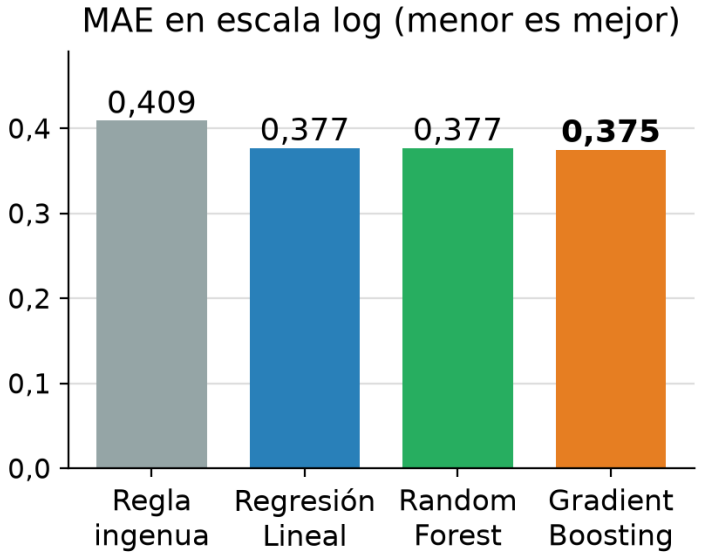
Búsqueda aleatoria + CV de 3 pliegues.

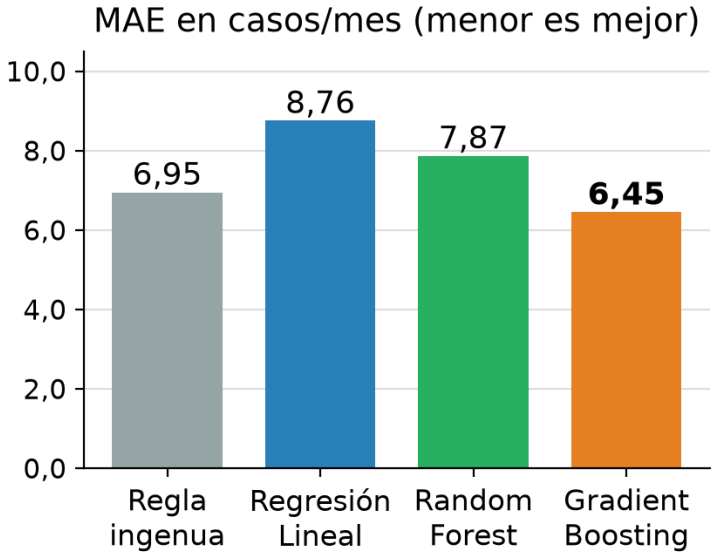
- Referencia: **regla ingenua** (“este mes = mes anterior”).
- Diseño: predecir la **variación** sobre el mes anterior (Random Forest: R^2 en casos de 0,68 a 0,97).
- No supervisado: **K-Means** (Silhouette y Davies-Bouldin).

predicción (log) = log(1 + casos del mes anterior) + **variación que aprende el modelo**

Resultados en el conjunto de prueba





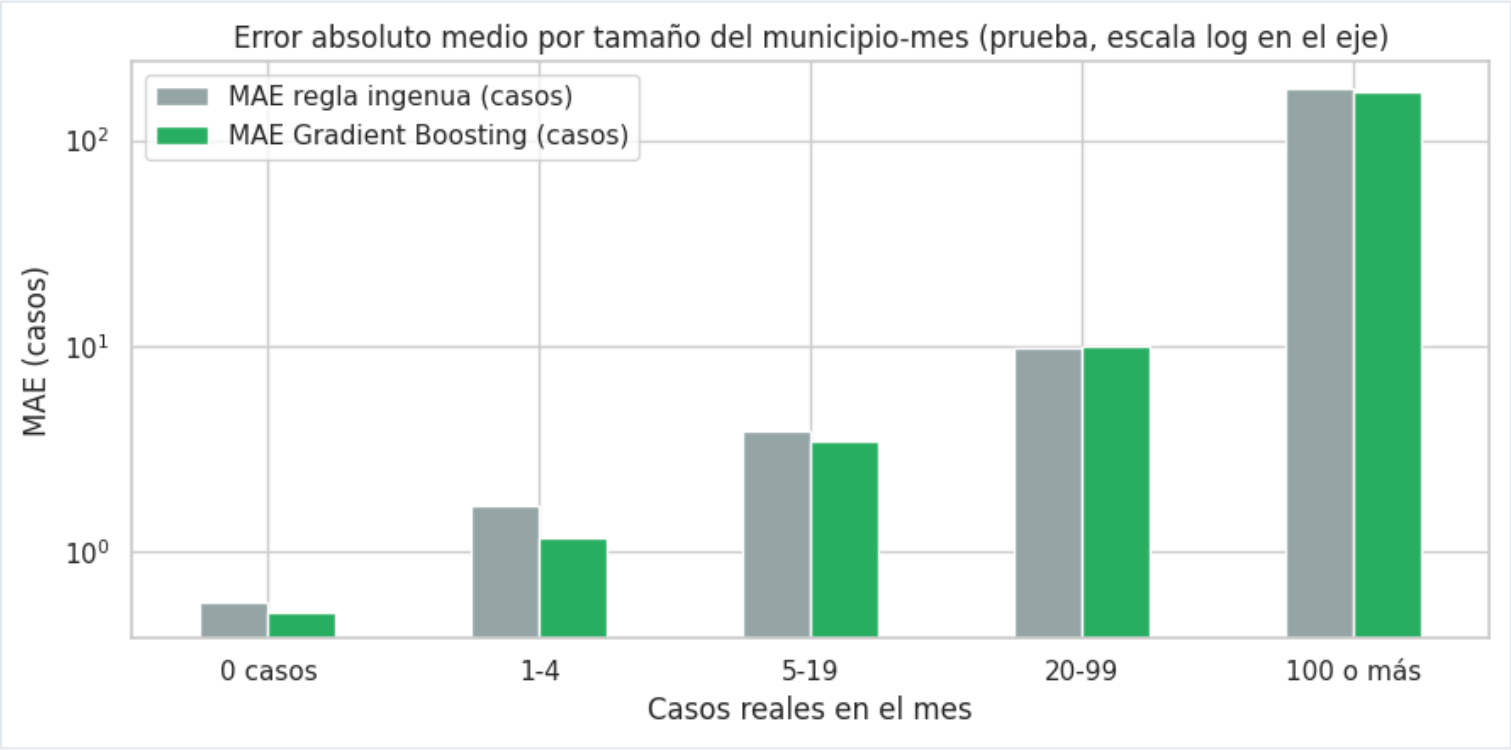


Modelo	R² log	MAE log	R² casos	MAE casos
Regla ingenua	0,797	0,409	0,983	6,95
Regresión Lineal	0,869	0,377	0,949	8,76
Random Forest	0,869	0,377	0,971	7,87
Gradient Boosting	**0,870**	**0,375**	**0,986**	**6,45**

- Todos superan la regla en log: mejora real (IC95 % no cruza 0).
- Entre ellos: **empate estadístico**.
- En casos solo **Gradient Boosting** supera la regla.

¿Dónde sirve el modelo?

- Error **−30 %** en municipios-mes de 1–4 casos; −11 % con 0 casos; −10 % en 5–19.
- 20–99 casos: empate (−1 %); 100 o más: mejora 5 %.
- Pesa el **historial** (acumulado 39 %, mes anterior 30 %); víctima o arma < 1,5 % c/u.
- Validación temporal (oct–dic): sigue superando la regla ingenua en log.



Modelo elegido: Gradient Boosting

- Único que supera la regla ingenua en **ambas escalas**.
- **Sin sobreajuste**: R^2 0,868 (entrenamiento) vs 0,870 (prueba).
- **Menor error en casos** en la validación temporal: 5,73 vs 6,21 de la regla.
- **Con honestidad:** en escala log empata estadísticamente con la Regresión Lineal (IC95 % −0,006 a 0,002); si importa explicar, la Lineal es defendible.

0,870
R^2 en prueba (log)

6,45
MAE en casos (regla: 6,95)

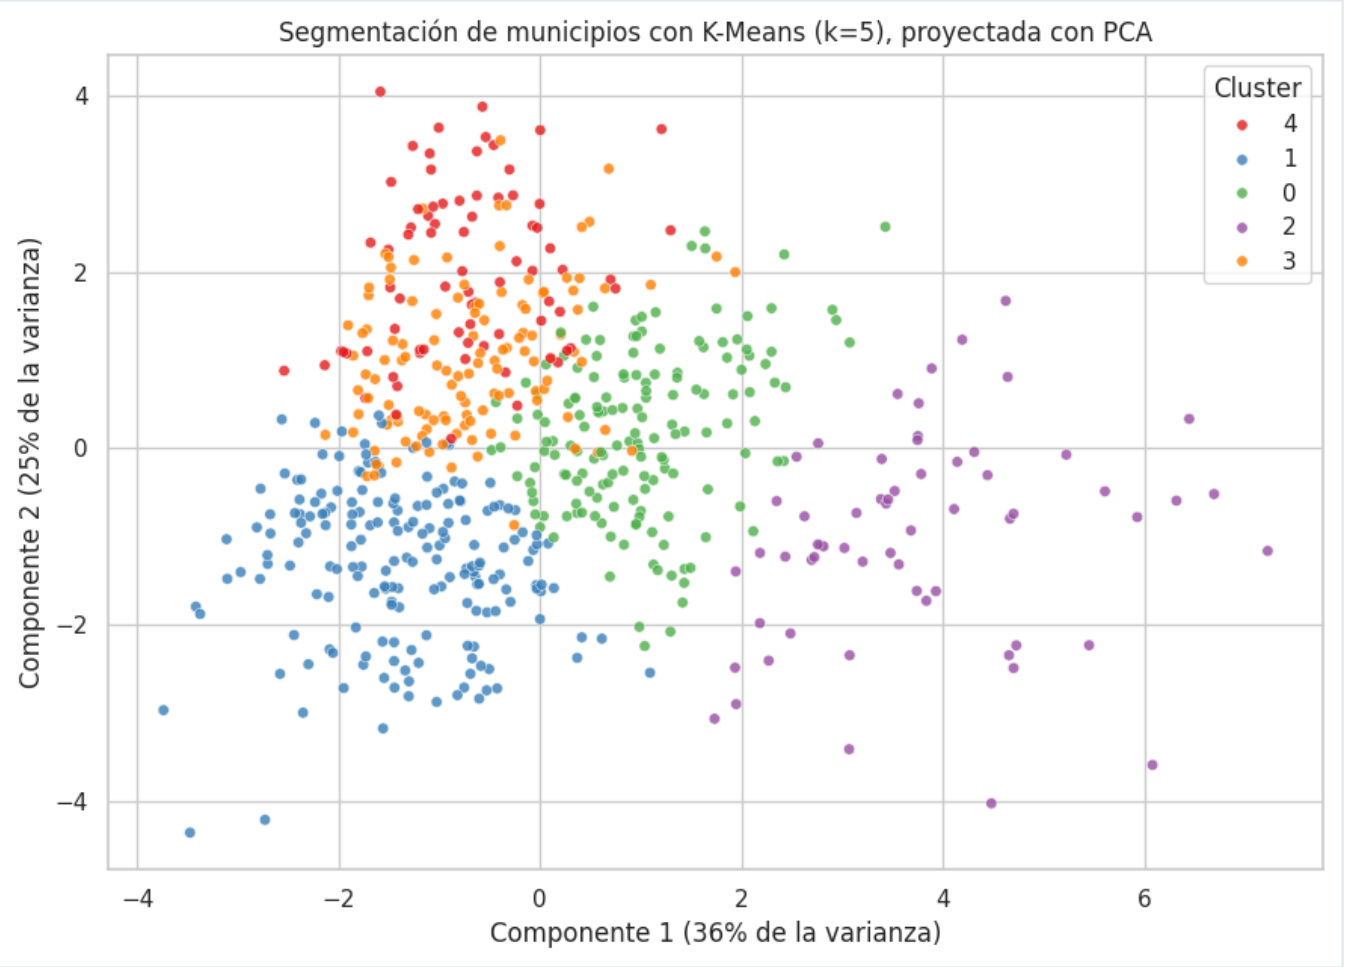
max_depth = 2
modelo poco complejo

Segmentación: 5 perfiles de municipio

606 de las 1.500 unidades (≥ 30 casos; 98,4 % de los casos) · k = 5

- **4** **Grandes ciudades**: 77 (86 % casos)
- **1** **Violencia intrafamiliar**: 185
- **2** **Violencia armada**: 62
- **3** **Hurto**: 123
- **0** **Intermedio mixto**: 159

Estructura débil (Silhouette 0,19): sirve para **orientar**, no como fronteras.



Conclusiones y mejoras

Conclusiones

- Mejora modesta (~8 % en error log): el mes anterior ya predice mucho.
- El valor está en municipios pequeños y medianos (−30 % en 1–4 casos).
- K-Means: 5 perfiles para orientar la política pública.

Limitaciones → mejoras

- Un solo año y rezago de reporte → más años (2022–2024) y corrección del rezago.
- Casos registrados, sin población → tasas por 100 mil habitantes (DANE).
- Cabeceras y centros poblados mezclados → agregar por municipio; modelos por segmento.

Idea central: el panel municipio-mes hizo posible el análisis; lo más decisivo fue **no eliminar**.

¡Gracias!

¿Preguntas?

Grupo 7

Juan David Quintero Garcia · Juan Jose Ospina · Miguel Angel Arboleda · Juan David Ascensio